

Речевые технологии. Шумоподавление.

Maksim Pikhenko

Задача шумоподавления

- **Задача:** Выделить чистый речевой сигнал $s(t)$ из наблюдения $x(t) = s(t) + n(t)$, где $n(t)$ — аддитивный шум.
- **Цель:** повышение разборчивости и субъективного качества речи; снижение WER систем распознавания.
- **Типы шумов:**
 - *Стационарные:* шум вентилятора, гул кондиционера (медленно меняющийся спектр).
 - *Нестационарные:* стук клавиатуры, чужая речь, музыка (быстро меняющиеся спектр и энергия).
- **Почему нестационарные шумы — главная сложность:**
 - сильное спектрально-временное перекрытие с речью $\Rightarrow$ низкая разделимость;
 - непредсказуемая структура во времени $\Rightarrow$ нужна адаптация и контекст;
 - высок риск «выкусывания» речевых элементов (транзиентов, согласных) при агрессивной фильтрации.
- **Ключевая проблема — компромисс:** сильное подавление $\Rightarrow$ меньше шума, но больше *искажений речи* (speech distortion); мягкое подавление $\Rightarrow$ меньше искажений, но больше остаточного шума.

● Интрузивные (требуют эталонный сигнал)

- **SDR, SI-SDR, SI-SNR:** Метрики, основанные на отношении сигнала к искажениям, являются стандартом в современных исследованиях.
- **PESQ:** Оценивает воспринимаемое качество речи, моделируя человеческое слуховое восприятие.
- **STOI:** Оценивает объективную разборчивость речи.
- **SBS:** Прямое сравнение двух аудиозаписей слушателем.

● Неинтрузивные (безэталонные)

- **MOS:** "Золотой стандарт" субъективной оценки живыми людьми.
- **DNS-MOS:** Нейросетевая модель для предсказания MOS в задачах шумоподавления.
- **NISQA:** Современная нейросетевая метрика для комплексной оценки качества речи.

MOS — Mean Opinion Score

- **MOS** считается “золотым стандартом” в оценке качества звука, так как он основан на прямом восприятии человеком.
- Это **неинтрузивный** метод, в ходе которого группа слушателей оценивает качество одного аудиофайла по абсолютной шкале (ACR - Absolute Category Rating), обычно от 1 до 5.
- Стандартная 5-балльная шкала выглядит так:
 - 5: Отлично (Искажения незаметны)
 - 4: Хорошо (Искажения заметны, но не мешают)
 - 3: Удовлетворительно (Искажения слегка мешают)
 - 2: Плохо (Искажения мешают)
 - 1: Очень плохо (Искажения очень мешают)
- Итоговая оценка — это среднее арифметическое всех оценок, полученных от слушателей.
- Главные недостатки этого метода — высокая стоимость, трудоемкость и длительность проведения.

- Метод субъективной оценки, при котором слушатель напрямую сравнивает два аудиофайла (например, обработанные двумя разными моделями) и выбирает лучший.
- Слушателю обычно предлагается три варианта ответа: "А лучше В", "В лучше А" или "А и В примерно одинаковы".
- Этот подход не дает абсолютной оценки качества, но позволяет эффективно ранжировать различные системы или алгоритмы шумоподавления.
- Для получения надежных результатов важен правильный дизайн эксперимента: слепое тестирование (слушатели не знают, какой файл какой моделью обработан) и рандомизация порядка файлов.
- SBS является интуитивно понятным для пользователей и часто используется для быстрой оценки преимуществ одной модели над другой.

SDR, SI-SDR — Signal-to-Distortion Ratio

- **Интрузивные** метрики измеряют отношение мощности целевого сигнала к мощности ошибок (шум, артефакты, искажения).
- **SDR (Signal-to-Distortion Ratio)** чувствителен к масштабированию сигнала, что может приводить к некорректным оценкам, если амплитуда восстановленного сигнала отличается от оригинала.
- **SI-SDR (Scale-Invariant SDR)** решает эту проблему путем проекции оцененного сигнала на эталонный перед вычислением.
- Пусть s — это эталонный сигнал, а $\hat{s}$ — восстановленный. Целевой сигнал и ошибка определяются как:

$$s_{\text{target}} = \frac{\langle \hat{s}, s \rangle}{\|s\|^2} s, \quad e = \hat{s} - s_{\text{target}}$$

$$\text{SDR} = 10 \log_{10} \frac{\|s\|^2}{\|e\|^2}$$

$$\text{SI-SDR} = 10 \log_{10} \frac{\|s_{\text{target}}\|^2}{\|e\|^2}$$

- **Диапазон:** Чем выше значение SI-SDR, тем лучше качество разделения.
- +3дБ - отношение сигнал-шум выше в 2 раза, 0 дБ - сигнал равен шуму

PESQ — Perceptual Evaluation of Speech Quality

- **Интрузивная** метрика, разработанная для объективной оценки воспринимаемого качества речи, хорошо коррелирует с MOS.
- Алгоритм сравнивает эталонный сигнал с обработанным, предварительно выполняя временное выравнивание и нормализацию уровня громкости.
- PESQ моделирует психоакустические процессы человеческого слуха для выявления слышимых искажений.
- **Диапазон** От -0.5 до 4.5 . Более высокие значения соответствуют лучшему качеству речи.
- Метрика стандартизирована в рекомендации ITU-T P.862 и долгое время была промышленным стандартом для оценки качества телефонии.

STOI — Short-Time Objective Intelligibility

- **Интрузивная** метрика, которая прогнозирует разборчивость речи, а не общее качество.
- Она измеряет корреляцию между временными огибающими коротких сегментов эталонной и обработанной речи.
- Основная идея заключается в том, что для понимания речи важна сохранность ее временной структуры на коротких промежутках времени.
- Значения метрики находятся в диапазоне от 0..1, где 0 означает полную неразборчивость, а 1 — идеальную разборчивость.
- STOI хорошо зарекомендовала себя в задачах, где приоритетом является сохранение понятности речи, например, для людей с нарушениями слуха.
- 0.95 — отличная разборчивость, 0.8 — хорошая, 0.6 – 0.7 — посредственно, < 0.5 — плохо.
- Подробнее можно прочитать в работе: C. N. Taal, R. C. Hendriks, R. Heusdens, J. Jensen, "An algorithm for intelligibility prediction of time-frequency weighted noisy speech".

- **Неинтрузивная** метрика, основанная на глубокой нейронной сети и разработанная Microsoft специально для оценки качества речи в задачах шумоподавления.
- Модель была обучена на огромном наборе данных, собранном в рамках челленджей INTERSPEECH Deep Noise Suppression. Этот набор содержит аудиофайлы с соответствующими им человеческими оценками MOS.
- DNS-MOS предсказывает три оценки:
 - **SIG**: Качество самой речи (насколько она искажена).
 - **BAK**: Качество фонового шума (насколько он естественен или раздражающ).
 - **OVRL**: Общая оценка качества.
- Отлично коррелирует с реальными MOS-оценками.
- Репозиторий проекта: <https://github.com/microsoft/DNS-Challenge>

- **Неинтрузивная** нейросетевая метрика для комплексной оценки качества и естественности речи.
- Она способна оценивать широкий спектр искажений, включая шум, реверберацию, обрывы связи и эффекты сжатия кодеками.
- Модель анализирует мел-спектрограмму аудиосигнала и предсказывает итоговую оценку MOS.
- Ее способность предсказывать MOS делает ее прямой заменой дорогостоящих и долгих субъективных тестов.
- Репозиторий проекта: <https://github.com/gabriel-guress/nisqa>

Современные Loss-функции в Шумоподавлении

- Выбор функции потерь (loss function) определяет, что модель считает “чистым” звуком.
- Три основные категории:
 - 1 Time-domain (временные)
 - 2 Frequency-domain (частотные)
 - 3 Комбинированные и перцепционные

1. Time-domain Losses: Работа с формой волны

• L1/L2 Loss (MAE/MSE)

- Формулы: $\mathcal{L}_{L1} = \frac{1}{T} \sum_t |y_t - \hat{y}_t|$, $\mathcal{L}_{L2} = \frac{1}{T} \sum_t (y_t - \hat{y}_t)^2$
- **Проблема:** Чрезвычайно чувствительны к фазовым сдвигам, что плохо коррелирует со слухом.

• SI-SNR (Scale-Invariant SNR) — Стандарт сегодня!

- Инвариантен к громкости (масштабу) сигнала.
- Измеряет отношение мощности целевого сигнала к мощности ошибки.
- В качестве лосса используется отрицательный SI-SNR: $\mathcal{L}_{SI-SNR} = -10 \log_{10} \frac{\|s_{\text{target}}\|^2}{\|e\|^2}$

2. Frequency-domain Losses: Работа со спектром (STFT)

• Loss на магнитудном спектре (L1/L2)

- Сравниваются только магнитуды (амплитуды) спектрограмм.
- Формула: $\mathcal{L}_{\text{mag}} = \sum_{f,n} \left| |S_{f,n}| - |\hat{S}_{f,n}| \right|$
- **Плюс:** Игнорирование фазы делает лосс более устойчивым.
- **Минус:** Потеря фазы может приводить к артефактам.

• Loss на комплексном спектре (L1/L2)

- Учитываются и магнитуда, и фаза.
- Формула: $\mathcal{L}_{\text{complex}} = \sum_{f,n} \|S_{f,n} - \hat{S}_{f,n}\|$
- Позволяет сохранить более естественное звучание.

3. Комбинированные и Перцепционные Лоссы

- **Multi-Resolution STFT Loss**

- Используется несколько STFT с разными параметрами (размер окна, наложение).
- Общий лосс — это сумма лоссов по всем STFT-представлениям.
- Позволяет улавливать и временные, и частотные детали.

- **Adversarial Loss (из GAN)**

- Генератор чистит речь, дискриминатор пытается отличить её от настоящей.
- Заставляет модель генерировать перцепционно неотличимый звук.

- **Loss на основе метрик (STOI, PESQ)**

- Прямая оптимизация метрик разборчивости (STOI) или качества (PESQ).
- Пример: $\mathcal{L}_{\text{STOI}} = 1 - \text{STOI}(y, \hat{y})$
- **Сложность:** Требуется дифференцируемых аппроксимаций.

- Звук в дискретном времени: $x[n]$
- Разбиение на перекрывающиеся фреймы длиной N с шагом H (hop)
- Окно $w[n]$, $n = 0, \dots, N - 1$
- Дискретная STFT:

$$X(m, k) = \sum_{n=0}^{N-1} x[n + mH] w[n] e^{-j2\pi kn/N}, \quad k = 0, \dots, N - 1$$

- $|X(m, k)|$ или $|X(m, k)|^2$ образуют спектрограмму: распределение энергии по времени и частоте

STFT Consistency




Figure 1: *Illustration of the concept of spectrogram consistency.*

Loss-функция: STFT Консистентность

Проблема: Неконсистентные спектрограммы

- Многие модели (особенно в frequency-domain) предсказывают *магнитудный* спектр $|\hat{S}|$, а фазу ϕ_x берут из исходного шумного сигнала.
- Сконструированный комплексный спектр $\hat{S} = |\hat{S}| \cdot e^{j\phi_x}$ не всегда является "валидным" или "STFT-консистентным".
- **Консистентность** означает, что обратное и прямое преобразование должны возвращать тот же спектр: $\hat{S} \approx \text{STFT}(\text{iSTFT}(\hat{S}))$.
- Если $\hat{S}$ неконсистентен, iSTFT (с чужой фазой) создает артефакты.

3. STFT Consistency Loss

- Это **дополнительный лосс (регуляризатор)**, который заставляет модель генерировать "валидные" спектрограммы.
- Пусть $\hat{S}$ — предсказанный моделью комплексный спектр:

$$\mathcal{L}_{\text{consistency}} = \mathbb{E} \left[\|\hat{S} - \text{STFT}(\text{iSTFT}(\hat{S}))\|_1 \right]$$

- **Практика:** Часто используется вместе с основным лоссом (например, L1 на магнитуде):

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{mag}}(|S|, |\hat{S}|) + \alpha \cdot \mathcal{L}_{\text{consistency}}(\hat{S})$$

- **Результат:** Уменьшает артефакты и улучшает естественность восстановленного сигнала, т.к. модель "выучивает" структуру STFT-преобразования.

- **Нет универсального решения:** Выбор лосса зависит от задачи и архитектуры.
- **Хорошая отправная точка:** SI-SNR для time-domain моделей, L1/L2 на магнитуде для frequency-domain.
- **Тренд:** Комбинация нескольких лоссов (например, SI-SNR + STFT loss) часто дает наилучший результат.
- **Для максимального качества:** Adversarial и перцепционные лоссы помогают достичь наиболее естественного звучания.

Подходы: Цели предсказания и области обработки

Что предсказываем?

- **Предсказание маски:** Модель учится предсказывать маску (например, Ideal Ratio Mask), которая затем применяется к спектру зашумленного сигнала для подавления шума.
- **Предсказание спектрограммы:** Модель напрямую генерирует спектрограмму чистого сигнала из зашумленной.
- **Прямое предсказание волны (end-to-end):** Модель работает непосредственно с аудиоданными (waveform), предсказывая чистую волну из зашумленной.

Что обрабатываем?

- **Frequency-domain:** Большинство подходов работает в частотной области (со спектрограммами), так как разделение речи и шума в ней часто является более простой задачей.
- **Time-domain:** End-to-end модели, работающие напрямую с сигналом. Потенциально могут избегать артефактов, связанных с преобразованием Фурье.

- **Causal (причинный) режим:**

- Модель для обработки текущего семпла использует только **прошлые** данные.
- Это приводит к небольшой задержке (типично 20-40 мс), что критически важно для real-time систем.
- **Применение:** онлайн-трансляции, звонки, видеоконференции.

- **Non-causal (непричинный) режим:**

- Модель для обработки текущего семпла может использовать как прошлые, так и **будущие** данные.
- Это позволяет достичь значительно более высокого качества шумоподавления.
- **Применение:** офлайн-обработка аудиозаписей, улучшение качества треков, постобработка видео.


Подходы: Архитектуры и парадигмы обучения

- **RNN/LSTM/BLSTM:** Исторически популярные архитектуры для обработки последовательных данных, хорошо подходят для моделирования временных зависимостей в аудио.
- **Demucs (U-Net подобные):** Современные сверточные архитектуры, такие как U-Net, адаптированные для 1D (временной) области. Эффективно захватывают как локальные, так и глобальные контексты.
- **Transformers:** Набирают популярность благодаря механизму внимания, который позволяет моделировать очень длинные зависимости в сигнале.
- **Использование GAN:** Вводится модель-дискриминатор, которая пытается отличить очищенную запись от настоящей чистой. Это заставляет генератор создавать более перцептивно качественный звук.
- **Диффузионные модели:** Современный подход, показывающий высочайшее качество генерации. Модель обучается постепенно "очищать" сигнал от шума за несколько шагов. Минус — долгое время обработки.


U-Net

Архитектура U-Net

Преобразует вход в выход такой же (или примерно такой же) размерности.



Пример работы U-Net для сегментации





A possible input and output of a U-Net. In this case, a grayscale input and a single channel binary output.

Demucs

Пример архитектуры: Demucs (U-Net в 1D)

- **Demucs (2019)** *Deep Music Separation* — одна из SOTA end-to-end (wave-to-wave) архитектур, изначально созданная для разделения музыки.
- Статья *Demucs: Deep Extractor for Music Sources with extra unlabeled data remixed*
<https://arxiv.org/pdf/1909.01174>
- Отлично подходит для шумоподавления (разделение на речь и шум).
- **Ключевая идея:** Применение архитектуры **U-Net** (популярной в 2D-сегментации изображений) напрямую к **1D аудио-сигналу** (waveform).
- **Time-domain подход:**
 - На вход подается "сырая" зашумленная волна $s(t)$.
 - На выходе получается "сырая" очищенная волна $\hat{s}(t)$.
 - **Плюс:** Модель избегает артефактов, связанных с STFT / iSTFT (преобразованием Фурье), таких как фазовые искажения или "музыкальный" шум.
- Модель обучается end-to-end, обычно с использованием **SI-SNR** или L1-loss во временной области.

Архитектура Demucs: 1D U-Net



Архитектура Demucs: 1D U-Net

- Архитектура представляет собой **кодировщик-декодировщик** с пробросом соединений (skip-connections).
- **1. Энкодер (Encoder):**
 - Набор 1D-сверток ('Conv1D') с шагом (stride) > 1 и увеличением каналов.
 - На каждом шаге он *уменьшает* временное разрешение (downsampling) и *увеличивает* число "признаков" (каналов).
 - Цель: получить сжатое представление, богатое семантикой.
- **2. Декодер (Decoder):**
 - Симметричный набор 1D-транспонированных сверток ('ConvTranspose1D').
 - На каждом шаге он *увеличивает* временное разрешение (upsampling) и *уменьшает* число каналов.
 - Цель: реконструировать сигнал из сжатого представления.
- **3. Skip-Connections (Проброс связей):**
 - Связи, соединяющие выходы энкодера с входами декодера на том же уровне.
 - **Критически важный элемент!** Позволяют декодеру "видеть" низкоуровневые детали (фазу, транзиенты) из исходного сигнала, которые теряются при сжатии.

Demucs: Bottleneck (LSTM) и Потери

- **Центральный элемент (Bottleneck):**

- В "бутылочном горлышке" (самом глубоком уровне U-Net) Demucs обычно использует **BLSTM** (двунаправленную LSTM).
- **Зачем?** Свертки (U-Net) отлично видят *локальный* контекст, а **LSTM моделирует длинные временные зависимости** (например, ритм речи, длительный фоновый гул).

- **Causal vs. Non-causal:**

- *Non-causal (Офлайн):* Используется BLSTM (смотрит в прошлое и будущее) $\Rightarrow$ максимальное качество.
- *Causal (Real-time):* Используется обычная LSTM (смотрит только в прошлое) $\Rightarrow$ ниже качество, но минимальная задержка.

- **Функция потерь (Loss Function):**

- Так как модель работает wave-to-wave, идеально подходит **SI-SNR Loss**.
- Часто комбинируют с L1 loss во временной области.
- Более продвинутые версии (Demucs v3/v4) используют **Multi-Resolution STFT Loss** вдобавок к временному лоссу для лучшего перцепционного качества.

- **Преимущества:**


- **End-to-End:** Не требует ручного проектирования признаков (как STFT).
- **Высокое качество:** Отсутствие артефактов STFT (фазовые искажения, "музыкальный" шум).
- **Мощная репрезентация:** Модель сама учит оптимальные фильтры для разделения.

- **Недостатки:**


- **Вычислительная сложность:** Работа с "сырой" волной (e.g., 16000 семплов/сек) требует больше вычислений, чем работа со спектрограммой (e.g., 100 фреймов/сек).
- **Требования к памяти:** 1D-свертки на длинных последовательностях "тяжелые".
- **Сложность обучения:** Фаза — очень чувствительный компонент, L1/L2 во временной области работают плохо (поэтому SI-SNR так важен).

Улучшения Demucs: HYBRID TRANSFORMERS FOR MUSIC SOURCE SEPARATION


<https://arxiv.org/pdf/2211.08553>



(a) Transformer Encoder Layer



(b) Cross-domain Transformer Encoder of depth 5



(c) Hybrid Transformer Demucs

Примеры работы

<https://ai.honu.io/papers/htdemucs/index.html>

Другие архитектуры

<https://arxiv.org/pdf/1709.08243>





Figure 2. Block diagram.







Figure 4. Example of noise suppression for babble noise at 15 dB SNR. Spectrogram of the noisy (top), denoised (middle), and clean (bottom) speech. For the sake of clarity, only the 0-12 kHz band is shown.



Comparison with other SE models

Method	Year	Structure	#Param.	WB-PESQ	CSIG	CBAK	COVL	STOI
Noisy	-	-	-	1.97	3.35	2.44	2.63	0.91
SEGAN [6]	2017	Waveform	43.2M	2.16	3.48	2.94	2.80	0.92
DEMUCS [8]	2021	Waveform	33.5M	3.07	4.31	3.40	3.63	0.95
SE-Conformer [9]	2021	Waveform	-	3.13	4.45	3.55	3.82	0.95
MetricGAN [26]	2019	Magnitude	-	2.86	3.99	3.18	3.42	-
MetricGAN+ [27]	2021	Magnitude	-	3.15	4.14	3.16	3.64	-
DPT-FSNet [15]	2021	Complex	0.88M	3.33	4.58	3.72	4.00	0.96
TridentSE [16]	2023	Complex	3.03M	3.47	4.70	3.81	4.10	0.96
DB-AIAT [21]	2021	Magnitude+Complex	2.81M	3.31	4.61	3.75	3.96	-
CMGAN [22]	2022	Magnitude+Complex	1.83M	3.41	4.63	3.94	4.12	0.96
PHASEN [30]	2020	Magnitude+Phase	20.9M	2.99	4.21	3.55	3.62	-
MP-SENet	2024	Magnitude+Phase	2.26M	3.60	4.81	3.99	4.34	0.96

<https://github.com/Xiaobin-Rong/gtcrn>




Fig. 3: Subband feature extraction module.




Fig. 2: Grouped temporal convolution block.






Fig. 4: Temporal recurrent attention module.


GTCRN comparison




(a) Noisy




(b) Enhanced by RNNoise




(c) Enhanced by GTCRN




(d) Clean




(e) Noisy



(f) Enhanced by RNNoise



(g) Enhanced by GTCRN



(h) Clean